

RELATÓRIO DE ENTREGA - FASE 2.5

Data: 10/10/2025

Assunto: Entrega da Fase 2.5 do Projeto ÓPERA - IA Assistente - Módulo 'Chat com Documentos' (MVP Funcional)

1. Resumo

Este relatório formaliza a entrega da Fase 2.5 do projeto "ÓPERA - IA Assistente". Esta fase introduz o segundo agente especializado da plataforma: o módulo "Chat com Documentos". Esta nova funcionalidade permite que os analistas interajam de forma conversacional com o conteúdo de um ou mais arquivos PDF, fazendo perguntas diretas e recebendo respostas contextuais.

A entrega representa um avanço significativo na arquitetura do sistema, com o desacoplamento do motor de Machine Learning para um serviço local e a implementação de um novo orquestrador de IA otimizado para diálogo. Este módulo estabelece a base técnica para futuros agentes interativos e solidifica a plataforma como um hub de IA versátil e modular.

A versão atual está concluída e pronta para ser utilizada em ambiente de produção para testes por usuários designados.

2. Objetivo da Fase 2.5 (Concluído)

O objetivo desta fase foi entregar um módulo de chat funcional, seguro e robusto, que permitisse aos analistas "conversar" com seus documentos. A conclusão desta etapa valida a arquitetura para agentes interativos e fornece uma ferramenta poderosa para a extração de insights específicos de grandes volumes de texto.

3. Funcionalidades Entregues (Para Teste em Produção)

A versão 2.5 do IA Assistente inclui as seguintes capacidades prontas para uso no módulo "Chat com Documentos":

1. Análise Conversacional de Documentos:

- **Carregamento de Múltiplos PDFs:** Permite carregar e consolidar o conteúdo de vários documentos em uma única sessão de chat.
- **Extração e Otimização de Contexto:** Oferece dois modos de preparação do conteúdo para a IA:
 - **Extração Bruta:** Utiliza o texto completo de todas as páginas, ideal para documentos curtos e diretos.
 - **Conteúdo Otimizado:** Reutiliza o pipeline de análise do módulo anterior para filtrar páginas irrelevantes ou repetitivas, otimizando o custo e o foco da IA.
- **Interação Inteligente:** Interface de chat que se comunica com a API da OpenAI, utilizando gerenciamento de cache de contexto (`previous_response_id`) para tornar as conversas longas mais rápidas e econômicas.

2. Interface de Usuário Intuitiva e Segura:

- Fluxo de Trabalho Guiado: Uma interface clara que guia o usuário pelas etapas de carregar arquivos, processar o conteúdo e iniciar a conversa.
- Gerenciamento da Conversa: O usuário tem controle total sobre o histórico do chat, com funcionalidades para editar, excluir, copiar ou "retomar" a conversa a partir de qualquer mensagem anterior.
- Autenticação Robusta: Utiliza o mesmo sistema de criação de conta e login seguro da plataforma, restrito a e-mails institucionais.

3. Configuração e Personalização Avançada:

- Drawer de Configurações Dedicado: Um painel de configurações específico para o módulo de chat, permitindo ajustes finos no comportamento da IA.
- Gerenciamento de Prompts de Sistema: O usuário pode escolher entre perfis de assistente, como "Estrito" (respostas apenas do documento) ou "Flexível" (permite conhecimento geral), além de poder criar um prompt "Personalizado".
- Seleção de Modelo e Parâmetros: Permite ao usuário selecionar o modelo de LLM desejado e ajustar parâmetros como temperatura e esforço de reflexão (para modelos compatíveis).

4. Métricas e Transparência:

- Monitoramento de Custos e Tokens: Uma barra de status exibe o total de tokens consumidos na sessão. Um diálogo detalhado (Ver detalhes do consumo) fornece um histórico completo de cada requisição, incluindo custos estimados em USD e BRL.

5. Arquitetura e Distribuição:

- Motor de ML Desacoplado: O modelo de embedding (Sentence Transformers) agora roda como um serviço local separado (engine.exe), gerenciado pela aplicação principal. Isso torna a aplicação principal mais leve e facilita futuras atualizações do motor de IA.
- Atualizador Automático: A infraestrutura de atualização (updater.py) está implementada, permitindo a distribuição simplificada de novas versões da aplicação e de seus componentes.

4. Acesso, Teste e Código-Fonte

A aplicação será distribuída como um executável para Windows, com pacote de instalação e instruções de configuração.

Requisito para teste: Para utilizar a funcionalidade de análise com IA, cada analista precisará de uma chave de API da OpenAI.

O feedback durante esta fase de testes é crucial. Solicitamos que todas as impressões, sugestões e eventuais erros encontrados sejam reportados para que possamos aprimorar a ferramenta continuamente.

Código-Fonte: Para fins de transparência técnica, auditoria e futuras colaborações, o código-fonte do projeto está disponível no repositório abaixo:

https://github.com/edson89braga/docs_analyzer_3

5. Próximos Passos (Roadmap para conclusão da Fase 3)

Esta entrega funcional do "Chat com Documentos" serve como base para as seguintes evoluções planejadas, que expandirão significativamente as capacidades da plataforma:

- **Ampliação de Tipos de Documentos:** Adicionar suporte nativo para arquivos .docx, .txt e outros formatos de texto; além de planilhas .xlsx e .csv.
- **Biblioteca de Prompts do Usuário:** Implementar uma funcionalidade para que os usuários possam salvar, gerenciar e reutilizar seus próprios prompts e templates de perguntas no chat.
- **Implementação de RAG Otimizado:** Integrar a técnica de Retrieval-Augmented Generation (RAG), possivelmente com LlamaIndex, para permitir a análise conversacional de volumes massivos de documentos (centenas ou milhares de páginas) de forma eficiente.
- **Módulo de Anonimização de Dados (NER):** Desenvolver a capacidade de identificar e anonimizar dados sensíveis (nomes, CPFs, etc.) com spaCy e Regex antes do envio para APIs externas.
- **Integração com LLM Local:** Adicionar suporte para a utilização de modelos de linguagem hospedados localmente ou em endpoints da rede corporativa, garantindo total privacidade e controle dos dados.